

Échantillonnage en grande dimension sous contraintes

Groupe de Lecture Apprentissage et Statistique

Pierre MINIER

IMS, Groupe Signal-Image

28 mars 2024

Article étudié

An MCMC Method for Uncertainty Quantification in Nonnegativity Constrained Inverse Problems

- Date : 2012
- Journal : Inverse Problems in Science and Engineering



(a) J. M. Bardsley, Montana



(b) C. Fox, Otago

Figure 1 – Les auteurs

Sommaire

- ① Contrainte de positivité vs non-négativité
- ② Échantillonnage sans contrainte
- ③ Échantillonnage sous contrainte de positivité
- ④ Échantillonnage sous contrainte de non négativité
- ⑤ Résultats de l'étude

Positivité vs non négativité

Contrainte de positivité (stricte)

Une probabilité nulle d'avoir des pixels nuls

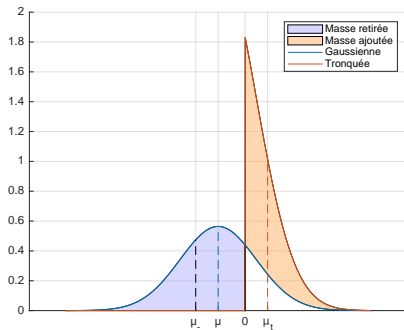
$$\{\mathbf{x} \in \mathbb{R}^N \mid \mathbf{x} > 0\}$$

Contrainte de non négativité


Une probabilité non nulle d'avoir des pixels nuls

$$\{\mathbf{x} \in \mathbb{R}^N \mid \mathbf{x} \geq 0\}$$

Exemples gaussiens



(a) Normale tronquée – Positivité



(b) Normale rectifiée – Non négativité

Figure 2 – Exemples possibles de modifications

Notations

Modèle d'observation linéaire

$$\mathbf{b} = \mathbf{A}\mathbf{x} + \boldsymbol{\eta} \quad (1)$$

- $\mathbf{b} \in \mathbb{R}^m$: mesures / observations connues
- $\mathbf{A} \in \mathbb{R}^{m \times n}$: matrice de mélange connue
- $\mathbf{x} \in \mathbb{R}^n$: vecteur à estimer
- $\boldsymbol{\eta} \in \mathbb{R}^m$: bruit de mesure aléatoire

Vraisemblance

Modèle blanc et gaussien du bruit

$$\boldsymbol{\eta} \sim \mathcal{N}\left(0, \lambda^{-1} \mathbf{I}_m\right)$$

λ : précision pouvant être estimée

Vraisemblance (*likelihood*)

$$\mathbf{b} \sim \mathcal{N}\left(\mathbf{Ax}, \lambda^{-1} \mathbf{I}_m\right)$$

$$p(\mathbf{b} \mid \mathbf{x}, \lambda) \propto \lambda^{m/2} \exp\left(-\frac{\lambda}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2\right)$$

A priori (*prior*) 1/2

Sur \mathbf{x} : distribution gaussienne

$$p(\mathbf{x} \mid \delta) \propto \delta^{n/2} \exp \left(-\frac{\delta}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} \right) \quad (3)$$

Matrice de régularisation \mathbf{C}

Soient \mathbf{x}_{∂_i} regroupant les n_i pixels voisin de x_i , et \bar{x}_{∂_i} leur moyenne.

$$x_i \mid \mathbf{x}_{\partial_i} \sim \mathcal{N}(\bar{x}_{\partial_i}, 1/n_i)$$

On obtient :

$$\mathbf{C}_{ij} = \begin{cases} n_i & i = j, \\ -1 & j \in \partial_i, \\ 0 & \text{sinon.} \end{cases}$$

A priori (*prior*) 2/2

Sur λ : distribution Gamma

$$p(\lambda) \propto \lambda^{\alpha_\lambda - 1} \exp(-\beta_\lambda \lambda) \quad (4)$$

Sur δ : distribution Gamma

$$p(\delta) \propto \delta^{\alpha_\delta - 1} \exp(-\beta_\delta \delta) \quad (5)$$

Pourquoi une Gamma ?

- 1 Conjuguée gaussienne \rightarrow marginales simples
- 2 Non informative pour $\alpha = 1$ et $\beta = 10^{-4}$

Modèle hiérarchique




Figure 3 – Les paramètres entourés sont estimés, les encadrés sont connus

A posteriori

Théorème de Bayes

$$\begin{aligned}
 p(\mathbf{x}, \lambda, \delta \mid \mathbf{b}) &= \frac{p(\mathbf{b} \mid \mathbf{x}, \lambda, \delta) p(\mathbf{x}, \lambda, \delta)}{p(\mathbf{b})} \\
 &= \frac{p(\mathbf{b} \mid \mathbf{x}, \lambda) p(\mathbf{x} \mid \delta) p(\lambda) p(\delta)}{p(\mathbf{b})} \\
 &\propto p(\mathbf{b} \mid \mathbf{x}, \lambda) p(\mathbf{x} \mid \delta) p(\lambda) p(\delta) \quad (2)
 \end{aligned}$$

Densité à posteriori

$$\begin{aligned}
 p(\mathbf{x}, \lambda, \delta \mid \mathbf{b}) &\propto \lambda^{\textcolor{red}{m}/2 + \alpha_\lambda - 1} \delta^{n/2 + \alpha_\delta - 1} \\
 &\exp \left(-\frac{\lambda}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 - \frac{\delta}{2} \mathbf{x}^t \mathbf{Cx} - \beta_\lambda \lambda - \beta_\delta \delta \right) \quad (6)
 \end{aligned}$$

Marginales

$$p(\mathbf{x}, \lambda, \delta \mid \mathbf{b}) \propto \lambda^{m/2+\alpha_\lambda-1} \delta^{n/2+\alpha_\delta-1} \exp \left(-\frac{\lambda}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 - \frac{\delta}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} - \beta_\lambda \lambda - \beta_\delta \delta \right)$$

Trois marginales

$$\mathbf{x} \mid \lambda, \delta, \mathbf{b} \sim \mathcal{N} \left(\mathbf{P}^{-1} \lambda \mathbf{A}^t \mathbf{b}, \mathbf{P}^{-1} \right) \quad (7)$$

$$\lambda \mid \mathbf{x}, \delta, \mathbf{b} \sim \Gamma \left(\frac{m}{2} + \alpha_\lambda, \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + \beta_\lambda \right) \quad (8)$$

$$\delta \mid \mathbf{x}, \lambda, \mathbf{b} \sim \Gamma \left(\frac{n}{2} + \alpha_\delta, \frac{1}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} + \beta_\delta \right) \quad (9)$$

Marginale de \mathbf{x}

$$p(\mathbf{x} \mid \lambda, \delta, \mathbf{b})$$

$$\propto \exp \left(-\frac{\lambda}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 - \frac{\delta}{2} \mathbf{x}^t \mathbf{Cx} \right)$$

$$\propto \exp \left(-\frac{\lambda}{2} \mathbf{x}^t \mathbf{A}^t \mathbf{Ax} + \frac{\lambda}{2} \mathbf{x}^t \mathbf{A}^t \mathbf{b} + \frac{\lambda}{2} \mathbf{b}^t \mathbf{Ax} - \frac{\lambda}{2} \mathbf{b}^t \mathbf{b} - \frac{\delta}{2} \mathbf{x}^t \mathbf{Cx} \right)$$

$$\propto \exp -\frac{1}{2} \left[\mathbf{x}^t (\lambda \mathbf{A}^t \mathbf{A} + \delta \mathbf{C}) \mathbf{x} - 2 \mathbf{x}^t (\lambda \mathbf{A}^t \mathbf{A} + \delta \mathbf{C}) (\lambda \mathbf{A}^t \mathbf{A} + \delta \mathbf{C})^{-1} \lambda \mathbf{A}^t \mathbf{b} \right]$$

$$\propto \exp -\frac{1}{2} \left[\mathbf{x}^t \mathbf{Px} - 2 \mathbf{x}^t \mathbf{PP}^{-1} \lambda \mathbf{A}^t \mathbf{b} \right]$$

$$\propto \exp -\frac{1}{2} \left[\left(\mathbf{x} - \mathbf{P}^{-1} \lambda \mathbf{A}^t \mathbf{b} \right)^t \mathbf{P} \left(\mathbf{x} - \mathbf{P}^{-1} \lambda \mathbf{A}^t \mathbf{b} \right) \right]$$

D'où :

$$\mathbf{x} \mid \lambda, \delta, \mathbf{b} \sim \mathcal{N} \left(\mathbf{P}^{-1} \lambda \mathbf{A}^t \mathbf{b}, \mathbf{P}^{-1} \right) \quad (7)$$

Méthode de Monte-Carlo par chaînes de Markov

```
k = 0;  
Initialiser  $\lambda_0$  et  $\delta_0$ ;  
while  $k < K$  do  
    Étape 1 : Tirer  $\mathbf{x}^k$  selon  $\lambda_k$  et  $\delta_k$ ;  
    Étape 2 : Tirer  $\lambda_{k+1}$  selon  $\mathbf{x}^k$ ;  
    Étape 3 : Tirer  $\delta_{k+1}$  selon  $\mathbf{x}^k$ ;  
     $k \leftarrow k + 1$ ;  
end
```

Algorithm 1: MCMC

Ajout de la contrainte de positivité

Gibbs : formulation équivalente de l'étape 1 du MCMC

$$p(x \mid \mathbf{x}_{-i}^k, \lambda_k, \delta_k) \propto \exp - \frac{\mathbf{P}_{ii}}{2} \left(x - \frac{\lambda_k([\mathbf{A}^t \mathbf{b}]_i - [\mathbf{A}^t \mathbf{A}_{-i} \mathbf{x}_{-i}^k]_i) - \delta_k \mathbf{C}_{-i} \mathbf{x}_{-i}}{\mathbf{P}_{ii}} \right)^2 \quad (11)$$

Avec :

- \mathbf{A}_{-i} et \mathbf{C}_{-i} les matrices \mathbf{A} et \mathbf{C} sans la colonne i
- \mathbf{x}_{-i} le vecteur \mathbf{x} sans la composante i

Contrainte de positivité

Tirer tour-à-tour les x_i^k selon :

$$p_+(x \mid \mathbf{x}_{-i}^k, \lambda_k, \delta_k) \propto p(x \mid \mathbf{x}_{-i}^k, \lambda_k, \delta_k) \mathbb{1}_+(x) \quad (12)$$

Échantillonner une loi tronquée univariée

Par rejet : en tirant parti de la proportionnalité

$\mathcal{L} :=$ un échantillonneur de la loi d'origine;

$x = -1$;

while $x < 0$ **do**

 | Tirer une proposition x selon \mathcal{L} ;

end

Algorithm 2: Procédure par rejet

(Dés)avantages

- Se généralise pour n'importe quelle dimension
- Coûteux selon l'importance de la troncature
Taux de rejet = aire de la partie tronquée de la densité

Échantillonner une loi tronquée univariée

Par rejet : en tirant parti de la proportionnalité




Figure 4 – Rejet de la masse bleue → réhaussement de la partie positive

Échantillonner une loi tronquée univariée

Inversion de la fonction de répartition

Explication

On cherche T tel que $X = T(U)$ avec $U \sim \mathcal{U}([0, 1])$

$$\begin{aligned}\phi(x) &= \Pr(X \leq x) \\ &= \Pr(T(U) \leq x) \\ &= \Pr(U \leq T^{-1}(x)) \\ &= T^{-1}(x) \\ T &= \phi^{-1}\end{aligned}$$

Cas gaussien tronqué

$$\phi_+^{-1}(u) = \mu + \sqrt{\frac{2}{\gamma}} \operatorname{erfinv} \left\{ (u - 1) \operatorname{erf} \left(\sqrt{\frac{\gamma}{2}} \mu \right) + u \right\} \quad (13)$$

Échantillonner une loi tronquée univariée

Démonstration

Notations

$$p_+(x) = K_+^{-1} p(x) \mathbb{1}_+(x)$$

$$\phi_+(t) = \Pr(X_+ \leq t)$$

$$\phi(t) = \Pr(X \leq t)$$

$$\begin{aligned} K_+ &= \int_{-\infty}^{+\infty} p(x) \mathbb{1}_+(x) \\ &= \int_0^{+\infty} p(x) \mathbb{1}_+(x) \\ &= 1 - \phi(0) \end{aligned}$$

Échantillonner une loi tronquée univariée

Démonstration

$$\begin{aligned}\phi_+(t) &= \int_{-\infty}^t p_+(x) dx \\ &= K_+^{-1} \left[\int_{-\infty}^t p(x) dx - \int_{-\infty}^0 p(x) du \right] \\ &= K_+^{-1} [\phi(t) - \phi(0)]\end{aligned}$$

$$\begin{aligned}\phi_+(t) &= u \\ t &= \phi^{-1}[K_+ u + \phi(0)] \\ \phi_+^{-1}(u) &= \phi^{-1}[(1 - u)\phi(0) + u]\end{aligned}$$

Récap. sur la contrainte de positivité

Points clefs

- Modification du MCMC avec une étape de Gibbs
- Ajout de la contrainte sur les marginales $x_i \mid \mathbf{x}_{-i}, \lambda, \delta$
- Échantillonnage par inversion de la fonction de répartition

Mais toujours pas de proportion non nulle de pixels nuls...

L'étape 1 du MCMC comme un système linéaire

Étape 1 du MCMC

On pose $\mathbf{P}_k = \lambda_k \mathbf{A}^t \mathbf{A} + \delta_k \mathbf{C}$ (diagonalisable avec Fourier).

Étape 1 : $\mathbf{x}^k \sim \mathcal{N}(\mathbf{P}_k^{-1} \lambda_k \mathbf{A}^t \mathbf{b}, \mathbf{P}_k^{-1})$

Système à résoudre

Trouver \mathbf{x}^k solution de :

$$\mathbf{P}_k \mathbf{x}^k = \lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k \quad (10)$$

où $\mathbf{w}_k \sim \mathcal{N}(0, P_k)$

L'étape 1 du MCMC comme un système linéaire

$$\mathbf{x}^k \sim \mathcal{N}(\mathbf{P}_k^{-1} \lambda_k \mathbf{A}^t \mathbf{b}, \mathbf{P}_k^{-1}) \quad (7)$$

$$\mathbf{P}_k \mathbf{x}^k = \lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k \quad (10)$$

\mathbf{w}_k est un vecteur gaussien : moyenne et covariance ?

$$\begin{aligned} \mathbb{E}[\mathbf{P}_k \mathbf{x}^k] &= \mathbf{P}_k \mathbb{E}[\mathbf{x}^k] = \mathbf{P}_k \mathbf{P}_k^{-1} \lambda_k \mathbf{A}^t \mathbf{b} = \lambda_k \mathbf{A}^t \mathbf{b} \\ &= \mathbb{E}[\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k] \end{aligned}$$

$$\begin{aligned} \mathbb{V}[\mathbf{P}_k \mathbf{x}^k] &= \mathbf{P}_k^t \mathbf{P}_k \mathbb{V}[\mathbf{x}^k] = \mathbf{P}_k^t \mathbf{P}_k \mathbf{P}_k^{-1} = \mathbf{P}_k^t = \mathbf{P}_k \\ &= \mathbb{V}[\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k] = \mathbb{V}[\mathbf{w}_k] \end{aligned}$$

$$\mathbf{w}_k \sim \mathcal{N}(0, \mathbf{P}_k)$$

Un problème d'optimisation

Formulation du problème d'optimisation

$$\mathbf{x}^k = \arg \min_{\mathbf{x}} \left\{ \frac{1}{2} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - \mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k) \right\} \quad (14)$$

$$f(x) = \frac{1}{2} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - \mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)$$

$$f'(x) = \mathbf{P}_k \mathbf{x} - (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)$$

$$f''(x) = \mathbf{P}_k : \text{semi-définie positive}$$

$$f'(x) = 0 \Leftrightarrow \mathbf{P}_k \mathbf{x} = \lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k \quad (10)$$

Ajout de la contrainte de non négativité

$$\mathbf{x}_{CON}^k = \arg \min_{\mathbf{x} \geq 0} \left\{ \frac{1}{2} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - \mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k) \right\} \quad (15)$$

Pourquoi cela fonctionne ?

En optimisation, on peut toucher la bordure : avoir une contrainte active ($x_i^k = 0$), contrairement aux lois de probabilités continues.

Lien avec l'échantillonnage sans contrainte

Minimisation d'une norme

$$\mathbf{x}_{CON}^k = \arg \min_{\mathbf{x} \geq 0} \|\mathbf{x} - \mathbf{x}_{UC}^k\|_{\mathbf{P}_k}^2 \quad (16)$$

$$\|\square\|_{\mathbf{P}_k}^2 = \square^t \mathbf{P}_k \square \quad (17)$$

$$\begin{aligned} \mathbf{x}^* &= \arg \min_{\mathbf{x} \geq 0} \|\mathbf{x} - \mathbf{x}_{UC}^k\|_{\mathbf{P}_k}^2 \\ &= \arg \min_{\mathbf{x} \geq 0} (\mathbf{x} - \mathbf{x}_{UC}^k)^t \mathbf{P}_k (\mathbf{x} - \mathbf{x}_{UC}^k) \\ &= \arg \min_{\mathbf{x} \geq 0} [\mathbf{x}^t - (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)^t \mathbf{P}_k^{-t}] \mathbf{P}_k [\mathbf{x} - \mathbf{P}_k^{-1}(\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)] \\ &= \arg \min_{\mathbf{x} \geq 0} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - 2\mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k) \\ &\quad + (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)^t \mathbf{P}_k^{-1} (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k) \end{aligned}$$

Lien avec l'échantillonnage sans contrainte

$$\begin{aligned}\mathbf{x}^* &= \arg \min_{\mathbf{x} \geq 0} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - 2\mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k) \\ &= \arg \min_{\mathbf{x} \geq 0} \frac{1}{2} \mathbf{x}^t \mathbf{P}_k \mathbf{x} - \mathbf{x}^t (\lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k)\end{aligned}\quad (15)$$

$$\mathbf{x}_{CON}^k = \arg \min_{\mathbf{x} \geq 0} \|\mathbf{x} - \mathbf{x}_{UC}^k\|_{\mathbf{P}_k}^2 \quad (16)$$

Dégénérescence de la matrice de régularisation

A priori de \mathbf{x} sans contrainte

$$p(\mathbf{x} \mid \delta) \propto \delta^{n/2} \exp \left(-\frac{\delta}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} \right) \quad (3)$$

Contrainte de non négativité

\mathbf{D}_x : matrice diagonale $[\mathbf{D}_x]_{ii} = \mathbb{1}(\mathbf{x}_i > 0)$

$$\frac{\delta}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} = \frac{\delta}{2} (\mathbf{D}_x \mathbf{C} \mathbf{D}_x) \mathbf{x}$$

Dégénérescence de la matrice de régularisation

A priori de \mathbf{x} avec contrainte

$$p(\mathbf{x} \mid \delta) \propto \delta^{n_p/2} \exp\left(-\frac{\delta}{2} \mathbf{x}^t \mathbf{C} \mathbf{x}\right)$$

n_p : nombre d'éléments positifs de \mathbf{x} .

Marginale de δ (Étape 3 MCMC)

$$\delta \mid \mathbf{x}, \lambda, \mathbf{b} \sim \Gamma\left(\frac{n_p}{2} + \alpha_\delta, \frac{1}{2} \mathbf{x}^t \mathbf{C} \mathbf{x} + \beta_\delta\right)$$

Les auteurs déclarent avoir de meilleurs intervalles de confiance après cette correction.

Un algorithme d'optimisation : GPCG

Gradient Projection – Conjugate Gradient (GPCG)

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \geq 0} \left\{ q(\mathbf{x}) = \frac{1}{2} \mathbf{x}^t \mathbf{B} \mathbf{x} - \mathbf{x}^t \mathbf{c} \right\} \quad (18)$$

$\mathbf{B} = \mathbf{P}_k = \lambda_k \mathbf{A}^t \mathbf{A} + \delta_k \mathbf{C}$: semi-définie positive

$$\mathbf{c} = \lambda_k \mathbf{A}^t \mathbf{b} + \mathbf{w}_k$$

- Algorithme de Moré et Torello (1991)
- Variante de *Conjugate Gradient*
- Grande dimension : nombre important de contraintes actives ajoutées ou supprimées à chaque itération

Expériences réalisées

- 3 expériences : reconstruction d'images en 1D, 2D, et tomographie
- 20 chaînes MCMC avec des départs aléatoires
- Critère d'arrêt selon des distances inter/intra-chaînes




Figure 5 – Expérience 1D

Résultats

1D	Vrai	UC	PC	NNC
λ	5.35	[3.94, 8.35]	[1.48, 3.73]	[3.61, 7.28]
Temps (sec)	×	36	52	49
2D	Vrai	UC	PC	NNC
λ	8.09	[7.59, 8.63]	×	[7.59, 8.63]
Temps (sec)	×	30	×	2 845
Tomographie	Vrai	UC	PC	NNC
λ	13.24	[13.85, 15.47]	×	[12.61, 13.53]
Temps (sec)	×	2 637	×	8 301

Conclusion

Points clefs

- Mise en place de contrainte de positivité / non négativité à partir d'un MCMC sans contrainte
- Estimation d'intervalle de confiance
- Positivité : avec un Gibbs
- Non négativité : par de l'optimisation
- Meilleurs résultats avec la non négativité (1D)

Référence

J. M. Bardsley and C. Fox. *An MCMC Method for Uncertainty Quantification in Nonnegativity Constrained Inverse Problems*. Inverse Problems in Science and Engineering, vol. 20, no. 4, pp. 477-498, 2012. DOI : 10.1080/17415977.2011.637208